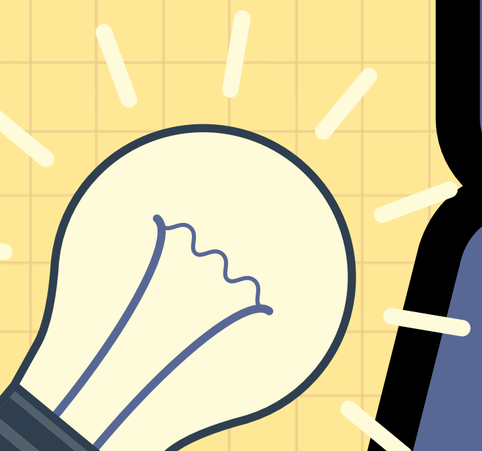
CUDA-Accelerated DNA Exact Pattern Matching

Jiratchaya Nonthanarak

6710404901



PROBELM AND OBJECTIVE

PROBLEM: ค้นหาทุกตำแหน่งที่ตรงกับรูปแบบ DNA ในลำดับ DNA ที่ยาว

OBJECTIVE:

- พัฒนาระบบจับคู่รูปแบบตามลำดับบน CPU
- พัฒนาระบบจับคู่รูปแบบแบบขนานโดยใช้ CUDA
- เปรียบเทียบความถูกต้องและเวลาในการประมวลผล
- วัดความเร็วของ GPU บนชุดข้อมูลขนาดใหญ่

DATASET

- Source: NCBI RefSeq, human chromosome 1

  (https://www.ncbi.nlm.nih.gov/nuccore/NC_000001.11?report=fasta)
- Accession: NC_000001.11
- Sequence length: approximately 248.96 million bases
- Alphabet: A, C, G, T (the sequence may also contain N)
- Search pattern: ACTAAGCA
- Pattern length: the entire sequence length

CPU Algorithms

Brute Force

- ตรวจสอบรูปแบบในทุกตำแหน่งเริ่มต้นที่เป็นไปได้
- เปรียบเทียบตัวอักษรทีละตัว
- Worst-case time complexity: (O(NM))

N คือความยาวของ DNA sequence และ M คือความยาวของรูปแบบที่กำหนด

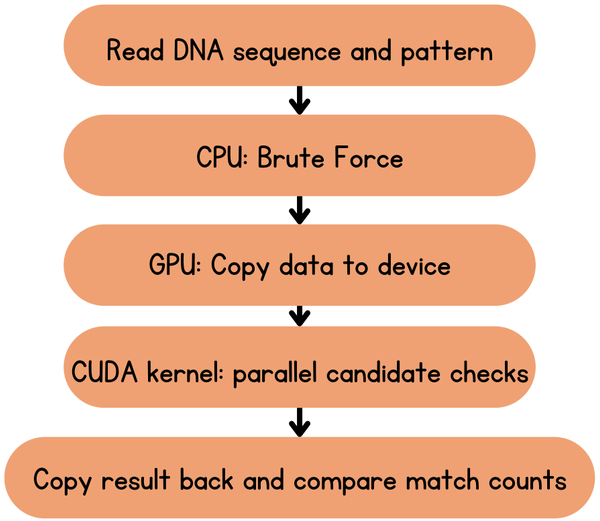
CUDA Parallel Algorithm

- กำหนดให้ CUDA thread หนึ่งตัวรับผิดชอบตำแหน่งเริ่มต้นที่เป็นไปได้แต่ละตำแหน่ง
- thread แต่ละตัวจะตรวจสอบว่า pattern ตรงกับข้อมูลที่ตำแหน่งนั้นหรือไม่
- หากพบว่าตรงกัน thread นั้นจะเพิ่มค่า shared result counter โดยใช้คำสั่ง `atomicAdd`
- CPU จะคัดลอกจำนวนผลลัพธ์ที่พบทั้งหมดกลับมาจาก GPU

NOTE: เนื่องจาก thread หลายตัวอาจพยายามอัปเดตตัวนับพร้อมกัน การใช้ atomic operation จึงช่วยป้องกันไม่ให้เกิดความขัดแย้งในการอัปเดตข้อมูลได้

Implementation

Workflow



เครื่องมือ/โปรแกรมที่ใช้

- C++ สำหรับ CPU implementation
- CUDA C++ และ nvcc สำหรับ GPU implementation
- Visual Studio Build Tools / MSVC บน Windows

Experimental Setup

- CPU: AMD Ryzen 5 7235HS (3.20 GHz)
- GPU: NVIDIA GeForce RTX 3050 6GB Laptop GPU
- RAM: 16 GB
- CUDA Toolkit: V13.3.73
- Dataset size: 3204
- Pattern length: 24895
- Compiler options: -O3 -std=c++17

RESULTS

```
PS C:\d\cuda_project> .\cpu_dna.exe .\chr1.fa .\pattern.txt
DNA length: 248956420 bases
Pattern: ACTAAGCA

--- CPU Brute Force ---
Matches: 3204
Time: 1084.595 ms
```

```
C:\d\cuda_project>cuda_dna.exe chr1.fa pattern.txt
DNA length: 248956420 bases
Pattern: ACTAAGCA
CUDA matches: 3204
Kernel time: 7.666 ms
End-to-end GPU time: 200.554 ms
```

Speedup and Discussion

Speedup

CUDA vs. CPU Brute Force: 5.408 ms

$$\text{Speedup} = \frac{\text{CPU Runtime}}{\text{CUDA Runtime}}$$

Discussion

GPU มีประสิทธิภาพเหนือกว่า CPU หรือไม่?

> GPU อาจเร็วกว่า CPU เมื่อข้อมูลมีขนาดใหญ่พอ เพราะสามารถตรวจสอบตำแหน่งเริ่มต้นหลายตำแหน่งพร้อมกันได้ แต่ไม่ได้เร็วกว่าเสมอไป

ระยะเวลาในการถ่ายโอนข้อมูลส่งผลต่อผลลัพธ์หรือไม่?

> ส่งผล การคัดลอกข้อมูลจาก CPU ไป GPU และนำผลกลับมาเพิ่มเวลา end-to-end หากข้อมูลเล็ก เวลาถ่ายโอนอาจมีสัดส่วนสูงจนลดหรือกลบข้อได้เปรียบของ GPU

ขนาดของชุดข้อมูลหรือความยาวของรูปแบบส่งผลต่อประสิทธิภาพอย่างไร?

> ชุดข้อมูลใหญ่ขึ้น: มีตำแหน่งให้ GPU ประมวลผลพร้อมกันมากขึ้น จึงอาจใช้ GPU ได้คุ้มขึ้น แต่เวลารวมและปริมาณข้อมูลที่ต้องถ่ายโอนก็เพิ่มขึ้น

> Pattern ยาวขึ้น: แต่ละ thread ต้องเปรียบเทียบตัวอักษรมากขึ้น งานต่อ thread จึงเพิ่มขึ้น และอาจทำให้ทั้ง CPU และ GPU ใช้เวลานานขึ้น

> Pattern สั้น: แต่ละตำแหน่งตรวจสอบได้เร็ว แต่เมื่อข้อมูลเล็กด้วย overhead ของการเปิด kernel และถ่ายโอนข้อมูลอาจมีผลมาก

CONCLUSION

Conclusion

- พัฒนาโปรแกรม DNA exact pattern matching ทั้งบน CPU และ GPU
- ใช้ CPU Brute Force และ CUDA เพื่อเปรียบเทียบประสิทธิภาพ
- ตรวจสอบความถูกต้องโดยเปรียบเทียบจำนวน matches
- วัด runtime และ speedup จากผลการทดลองจริง

Limitations

- CUDA kernel ตรวจสอบแต่ละตำแหน่งด้วยการเปรียบเทียบ pattern จึงมีงานประมาณ (O(NM))
- atomicAdd อาจกลายเป็นคอขวดเมื่อพบ matches จำนวนมาก
- การคัดลอกข้อมูลระหว่าง CPU และ GPU เพิ่ม overhead
- ผลการทดลองขึ้นอยู่กับ GPU, CPU, ขนาดข้อมูล และความยาว pattern

THANK YOU

Presented by

จิรัชญา นนทนารักษ์

6710404901